

S Y V . A I

ET PERSPEKTIV PÅ AI-OPERATIONEL MODENHED · Q2 2026

EvalOps

Fra prototype til pålidelig AI i drift — hvorfor evaluering bliver den næste operationelle disciplin

Udarbejdet af syv.ai · København

Fortroligt materiale · Til intern drøftelse hos modtageren

HVORFOR NU

Markedet har passeret pilotfasen — de operationelle spørgsmål er nu de vigtige

2022–2023

Eksperiment

KERNESPØRGSMÅL

“Kan modellen det?”

Proof-of-concepts, prompt-engineering, inspirations-demoer. Fokus: mulighed.

2024–2025

Pilot

KERNESPØRGSMÅL

“Virker det for én bruger?”

Interne pilotbrugere, afgrænsede use cases, manuelle processer omkring. Fokus: værdi.

2026+

Drift

KERNESPØRGSMÅL

“Virker det for tusind — dagligt?”


Produktionsudrulning, SLA'er, regulering, økonomi. Fokus: pålidelighed.

SKIFTET


Spørgsmålene har flyttet sig fra *“kan modellen det?”* til **“virker hele systemet — stadig — i morgen?”**

DEN SKJULTE KOMPLEKSITET

Modellen udgør <5% af det arbejde der skal til for at få AI i drift



FORDELING AF INDSATS

Baseret på typisk projektfordeling (teknisk del)*Illustrativ fordeling; varierer efter use case og modenhed*

HOVEDBUDSKAB

AI-projekter fejler sjældent på modellen — de fejler på manglende evaluering i drift.

01

Problemet er operationelt, ikke teknisk

73% af GenAI-pilotprojekter når aldrig produktion. Den primære årsag er ikke modelkvalitet, men fraværet af systematisk måling af output over tid.

02

EvalOps bliver en selvstændig disciplin

På samme måde som DevOps og MLOps opstod som svar på skalaproblemer, modnes EvalOps nu som praksis for at gøre AI-systemer målbare, reviderbare og regulatorisk forsvarlige.

03

Vinderne bygger måleapparatet først

Organisationer der investerer i eval-infrastruktur før skalering, opnår 3-5x hurtigere iteration og markant lavere risiko for silent regression i produktion.

MARKEDSKONTEKST

GenAI-adoption er høj, men operationel modenhed halter markant bagud

Tre bevægelser driver behovet

● Skalering

LLM-baserede features rulles ud til kundeblader, sagsbehandling og beslutningsstøtte — men uden konsistent kvalitetsmåling.

● Regulering

EU AI Act, GDPR-praksis og sektorspecifikke krav (finans, sundhed, offentlig forvaltning) gør dokumenteret evaluering obligatorisk.

● Non-determinisme

Samme prompt kan give forskellige svar. Klassisk QA-tankegang bryder sammen — test skal blive statistisk og kontinuerlig.

DRIFTSREALITETEN

73%

af GenAI-piloter når ikke produktion

41%

af virksomheder har ingen formel eval-proces

3-5x

hurtigere iteration ved eval-first tilgang

Kilder: Gartner, McKinsey State of AI, syv.ai client engagements

DEFINITION

EvalOps er den disciplin der gør AI-output målbart, sammenligneligt og reviderbart over tid

EvalOps /i:'væl.ɒps/ · substantiv.

Den kontinuerlige praksis for at definere, måle og forbedre AI-systemers output-kvalitet gennem hele livscyklussen — fra prompt-udvikling til produktionsmonitorering.

Evolutionen af operationelle discipliner

2010'ERNE

DevOps

Kernespørgsmål

“Virker koden?”

Primære KPI'er

Uptime, release-kadence

SENT 2010'ERNE

MLOps

Kernespørgsmål

“Virker modellen?”

Primære KPI'er

Accuracy, drift, latency

2020'ERNE

EvalOps

Kernespørgsmål

“Virker outputtet — stadig?”

Primære KPI'er

Kvalitet, sikkerhed, omkostning

KONFLIKTEN

Traditionel kvalitetssikring antager, at samme input giver samme output hver gang eks. software.

KLASSISK SOFTWARE

Deterministisk: samme input → samme output

Binær verifikation: bestået/fejlet

Få test-cases dækker stort inputrum

Regression fanges ved unit tests

Ejes af QA-team i sprint-cyklus

LLM - VIRKELIGHED

Stokastisk: samme input → forskellige outputs

Gradueret kvalitet: bedre/værre, sjældent forkert

Input er fri tekst — rummet er nær uendeligt

Regression er ofte usynlig i enkelt-outputs


Kræver løbende eval på tværs af produkt, ML og jura

Konsekvens: Uden EvalOps opdages kvalitetsforringelse først når en bruger eller journalist gør det (ref. "Velkommen til forsiden på EB).

KONFLIKTEN I PRODUKTION

Kvalitet i outputtet af AI model kan blive bedre eller dårligere, og uden kontinuerlig Eval opdages det ofte for sent.

Output-kvalitet over tid (illustrativ)



HVAD FORÅRSAGER DRI FT?

- Modelopdatering**
Leverandør ændrer bag kulisserne
- Kildedata ændrer sig**
Ny terminologi, nye formater
- Bruger-mønstre skifter**
Nye use cases sniger sig ind
- Prompt-justeringer hober op**
Små ændringer akkumulerer

EVALOPS - RAMMEVÆRKET

Hvordan gør vi output af en AI app til en målbar, kontrollerbar størrelse

01



Definition

Hvad er godt output?

Konkrete kriterier pr. use case: korrekthed, fuldstændighed, forklarbarhed, tone, sikkerhed, konsistens, format, svartid, kildebrug, omkostning. Men vigtigst anvendelighed. Forankret hos forretningen — ikke kun hos udviklere.

02



Datasæt

Hvad tester vi på?

Kuraterede eval-sæt: golden-dataset, træningssæt, edge cases, adversariale prompts, produktions-samples, historiske fejl, kendte failure modes, produktions samples. Segmentering pr. use case og risiko niveau. Versioneret og vedligeholdt som kode.

03



Metoder

Hvordan scorer vi?

Kombination af regelbaseret, LLM-as-judge og human review. Afstemt efter risiko og volumen — ikke alt skal vurderes manuelt.

Automatiske checks for format, policy-brud, kildekrav og strukturelle fejl. Regressionstest ved modelskift, promptændringer og nye workflows.

04



Drift

Hvad sker der nu?

Kontinuerlig monitorering, regression-alarmer og feedback-loops fra produktion tilbage til eval-sættet. Overvågning af kvalitet, svartid, omkostning og stabilitet over tid. Detektion af drift i prompts, brugerafdærd, datagrundlag og modeloutput. Alerting ved fald i performance eller ændringer i adfærd. Produktionsfejl fødes tilbage som nye testcases.

MECE-princip: Hvert lag adresserer ét spørgsmål. Uden alle fire opstår blinde vinkler.

EVALOPS - RAMMEVÆRKET

Eksempler.

01



Definition

Hvad er godt output?

Eksempel:

Korrekthed: Svaret gengiver virksomhedens regler korrekt.

Kunden må ikke få besked om, at varen kan returneres efter 60 dage, hvis policy siger 30.

02



Datasæt

Hvad tester vi på?

Eksempel:

Golden dataset: 100 kendte sager med facit fra erfarne sagsbehandlere.

Eksempel: Carport på 48 m², udestue i sommerhusområde, kvist i bevaringsområde.

03



Metoder

Hvordan scorerer vi?

Eksempel:

Regelbaserede checks: Tjek om brevet altid indeholder korrekt medlemsnummer-format, obligatorisk disclaimer og korrekt signatur.**LLM-as-judge:** En dommermodel scorer, om brevet er klart, venligt og handlingsorienteret på en skala fra 1-5

04



Drift

Hvad sker der nu?

Eksempel:


Kontinuerlig monitorering:

Følg dagligt med i svar-kvalitet, svartid, omkostning pr. svar og andel af svar der bliver redigeret af mennesker.

Regression-alarmer: Hvis korrektheden falder fra 92% til 84% efter et promptskift, udløses alarm.*MECE-princip: Hvert lag adresserer ét spørgsmål. Uden alle fire opstår blinde vinkler.*

EVALOPS-RAMMEVÆRKET: GUARDRAILS.

Hvor passer EvalOps ind i arkitekturen.

**DESIGN PRINCIPPER.****● Deterministisk før probabilistisk**

Regel-check er billigere og hurtigere end LLM-check

● Testbar i isolation

Hver guardrail skal kunne evalueres selvstændigt

● Fejl åbent, ikke tyst

Blokerede kald skal logges og vises, ikke skjules

● Graceful degradation

Guardrail-nedbrud må ikke vælte hele systemet

EVALOPS-RAMMEVÆRKET: FEEDBACK.

Feedback som afgørende komponentet i EvalOps.



EksPLICIT positiv

Bruger klikker “godt svar”, stjerner, godkendelse

- + Klart signal
- Lav deltagelse



EksPLICIT negativ

Bruger flag, klage, rapportering

- + Identificerer fejl
- Kun motiverede rapporterer



Implicit adfærd

Tid brugt, scroll, copy-paste, follow-up-spørgsmål

- + Høj volumen
- Svært at fortolke



Udfaldsbaseret

Blev sagen løst? Solgt? Lukket?

- + Direkte værdi-korrelation
- Forsinket signal

Robuste systemer bruger alle fire — de triangulerer sandheden på tværs

EVALOPS-RAMMEVÆRKET: FEEDBACK SIGNALER.

Hvor hurtigt vi får feedback på kvalitet — og hvor hurtigt den kan omsættes til forbedringer?

System-telemetri
Sekunder

Latency, fejl, timeout,
token-forbrug

Bruger-UI-signaler
Sekunder–minutter

Thumb up/down, kopier, scroll, follow-up

Support-tickets
Timer–dage

Kundeklager, hjælp-anmodninger

Udfalds-data
Dage–uger

Sag lukket/åben, salg, NPS

Audit & review
Uger–måneder

Stikprøver, compliance-reviews

← Hurtigere signal, mindre kontekst Langsommere signal, rigere kontekst →

EVALOPS-RAMMEVÆRKET: FEEDBACK SIGNALER.

Selvom vi overvåger alt, er der stadig behov for ”menneskeligt tilsyn”.

Human-in-the-loop <i>Menneske godkender før handling udføres</i>	RISIKO-NIVEAU Høj risiko	TYPISK FOR Juridisk, medicinsk, finansielt	GENNEMSTRØMNING Lav	OMKOSTNING Høj
Human-on-the-loop <i>Model handler selv, menneske reviewer løbende</i>	RISIKO-NIVEAU Moderat	TYPISK FOR Kundeservice, sagsbehandling	GENNEMSTRØMNING Middel	OMKOSTNING Middel
Human-out-of-loop <i>Model handler autonomt; reviews er stikprøver</i>	RISIKO-NIVEAU Lav	TYPISK FOR Suggestions, autocomplete	GENNEMSTRØMNING Høj	OMKOSTNING Lav

OBS · Human-in-the-loop er ikke midlertidigt. Det er et bevidst valg, ikke manglende modenhed.

EVALOPS - RAMMEVÆRKET: OPERATING MODEL.

EvalOps – operating model. Hvem er ansvarlig for hvad og hvornår.

ROLLE / BESLUTNING	Prompt-ændring	Model-skift	Context-udvidelse	Policy-opdatering
Engineering	A	R	A	I
Produkt	R	A	R	C
Compliance/jura	C	C	C	R
Forretning	I	C	I	A

R Responsible — udfører

A Accountable — ejer beslutningen


C Consulted — høres før

I Informed — orienteres efter

MODENHEDSKURVE

De fleste organisationer befinder sig på trin 1-2; konkurrencefordelen ligger på trin 4-5

Indsigt: 85% af organisationer opererer på trin 1-3. Springet fra trin 3 til trin 4 kræver investering i infrastruktur, men giver 3-5x hurtigere iteration og markant lavere produktionsrisiko.



RETNING: OPERATIONEL MODENHED →

Estimat baseret på syv.ai-engagements og branche-benchmarks 2025-2026

Fortroligt · Kun til intern drøftelse

ARKETYPER

Evalueringsbehovet skalerer med risiko — ikke med modellens størrelse

↑ RISIKO

HØJ RISIKO · LAV VOLUMEN Juridiske klausuler, medicinsk beslutningsstøtte <i>Primært human review + struktureret eval</i>	HØJ RISIKO · HØJ VOLUMEN Kundeservice i finans, sagsbehandling <i>LLM-judge + stikprøver + regression</i>
LAV RISIKO · LAV VOLUMEN Intern produktivitet, idégenerering <i>Let stikprøvekontrol</i>	LAV RISIKO · HØJ VOLUMEN Autocomplete, søgeforslag, summarization <i>Automatisk metrics + A/B-test</i>

VOLUMEN →

PRINCIP

Match eval-investering til risiko

Overevaluering af lav-risiko use cases dræner budgetter.

Underevaluering af høj-risiko use cases skaber juridisk og omdømmemæssig eksponering.

ROADMAP

En pragmatisk 90-dages vej fra ad hoc til kontinuerlig evaluering

UGE 1-2

Diagnose

Kortlæg eksisterende AI-features, risikoklassificer use cases, identificér målehul.

UGE 3-6

Fundament

Byg første eval-sæt (30-50 cases) for den mest kritiske use case. Definér kvalitetskriterier med forretningsejere.

UGE 7-10

Automatisér

Integrér eval i CI/CD. Tilføj LLM-judge og regression-alarmer. Etablér ugentlig review-kadence.

UGE 11-13

Skalér

Udrul til næste use case. Implementér produktions-monitorering og feedback-loop fra bruger til eval-sæt.



Resultat efter 90 dage: Målbart kvalitet på én produktionskritisk use case, automatiseret regression, og et replikerbart playbook for resten af porteføljen.

ANTI-PATTERNS

Fem tilbagevendende fejl der underminerer selv veldesignede eval-programmer

01 Vanity-metrics

At måle det **lette** (længde, latens) frem for det relevante (korrekthed, sikkerhed).

02 Eval-stagnation

Eval-sæt der ikke opdateres følger med modellens blinde vinkler, ikke foran dem.

03 LLM-judge-monokultur

Én model dømmer en anden — korrelerede fejl bliver usynlige uden human stikprøve.

04 Forretnings-frakobling

Eval ejes af engineering alene; kvalitetskriterierne afspejler ikke forretningens virkelighed.

05 Optimering mod benchmark

Systemet bliver godt til testen, ikke til opgaven. Klassisk Goodhart's law.

TRE HANDLINGER DE NÆSTE 30 DAGE

Konkrete, lavrisiko-skridt der skaber målbar fremdrift uden at kræve stort programbudget

01



Lav en risiko-kortlægning

Identificér alle steder AI træffer eller understøtter beslutninger. Klassificér hver efter konsekvens og volumen.

Ansvarlig: CTO / AI-lead

Tidslinje: ≤ 1 uge

02



Byg ét eval-sæt i denne måned

Vælg den mest kritiske use case. Kurater 30-50 realistiske cases med forventede outputs. Versionér i Git.

Ansvarlig: Produkt + ML

Tidslinje: 2-3 uger

03



Gør eval til en del af release-kriteriet

Ingen prompt- eller modelændring går i produktion uden at passere eval. Start simpelt — automatisér senere.

Ansvarlig: Engineering

Tidslinje: Løbende

A F S L U T T E N D E T A N K E

Den organisation der *måler* sin AI-kvalitet vinder over den der kun *bygger* den.

EvalOps er ikke et værktøj, man køber. Det er en disciplin, man etablerer — og jo tidligere, jo billigere.

D I A L O G

syv.ai · København

Vi hjælper organisationer fra ad hoc til kontinuerlig evaluering